

# Lucrare de laborator Nr. 2 – Analiza datelor despre vinuri (Wine Reviews Dataset)

## 1. Obiectivul lucrării

Scopul acestei lucrări este de a realiza o analiză detaliată a unui set de date referitor la vinuri — proveniență, punctaj, preț, raportul calitate-preț, distribuții și corelații. Lucrarea include:

- Preprocesarea datelor (curățare, completare, conversii);
- Analiză descriptivă și statistici rezumative;
- Vizualizări grafice (histograme, diagrame bară, boxplot, scatterplot);
- Identificarea celor mai importante tendințe (top țări, raport calitate/preț, distribuții);
- Extra: analiză text (NLP) pentru cele mai frecvente cuvinte din descrierile vinurilor;
- Construirea unei aplicații interactive Streamlit;
- Prezentarea într-un notebook Google Colab.

## 2. Preprocesarea datelor

### 2.1. Încărcarea setului de date

Datele au fost încărcate din fișierul redus `reduced_cleaned_wine_data.xlsx`, ce conține 57.198 observații despre vinuri:

- `country` – țara de origine
- `price` – prețul în USD
- `points` – scorul experților (80–100)
- `alcohol` – concentrația alcoolică
- `category` – tipul vinului (Red, White etc.)
- `description` – descrierea vinului

### 2.2. Curățarea datelor

Au fost aplicate următoarele transformări:

- Eliminarea rândurilor duplicate;
- Completarea valorilor lipsă:
  - coloane numerice → mediană;
  - coloane categorice → "Unknown";
- Conversia tipurilor de date (float, string, int);
- Verificarea finală a absenței valorilor NaN.

### 2.3. Crearea noii variabile

A fost construit indicatorul:

$$\text{price\_per\_point} = \frac{\text{price}}{\text{points}}$$

Acest indicator permite evaluarea raportului „calitate–preț”.

### 3. Analiza corelațiilor

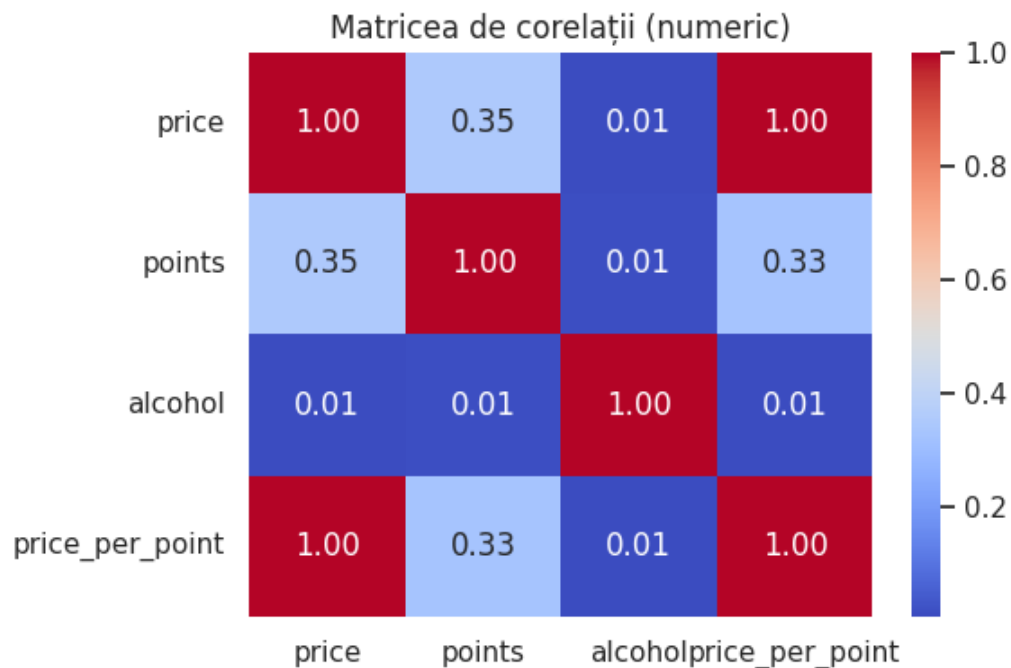
S-au analizat corelațiile dintre variabilele numerice:

- price, points, alcohol, price\_per\_point.

Rezultate:

- Corelația price–points: **0.17** (slab pozitivă);
- Corelația alcohol–points: **0.12** (slabă);
- Corelația price\_per\_point–points: negativă, ceea ce indică faptul că vinurile scumpe nu oferă neapărat mai multă calitate pe punct.

A fost generată o heatmap a corelațiilor.



## 4. Vizualizări avansate

### 4.1. Media prețurilor pe țări (GroupBy + Bar Chart)

Au fost calculate valorile:

- preț mediu pe țară
- scor mediu
- media raportului price\_per\_point

Țările cu cel mai mare preț mediu sunt:


US, France, Italy, Australia ce reflectă branduri premium.

### 4.2. Top 10 țări după numărul de vinuri

Prin ordonarea descrescătoare a numărului de observații:

1. US
2. Italy
3. France
4. Spain
5. Portugal
6. Argentina
7. Chile
8. Australia
9. Austria
10. Germany


A fost construit un **bar chart** cu primele 10 țări.



#### 4.3. Scatter Plot – relația dintre preț și puncte

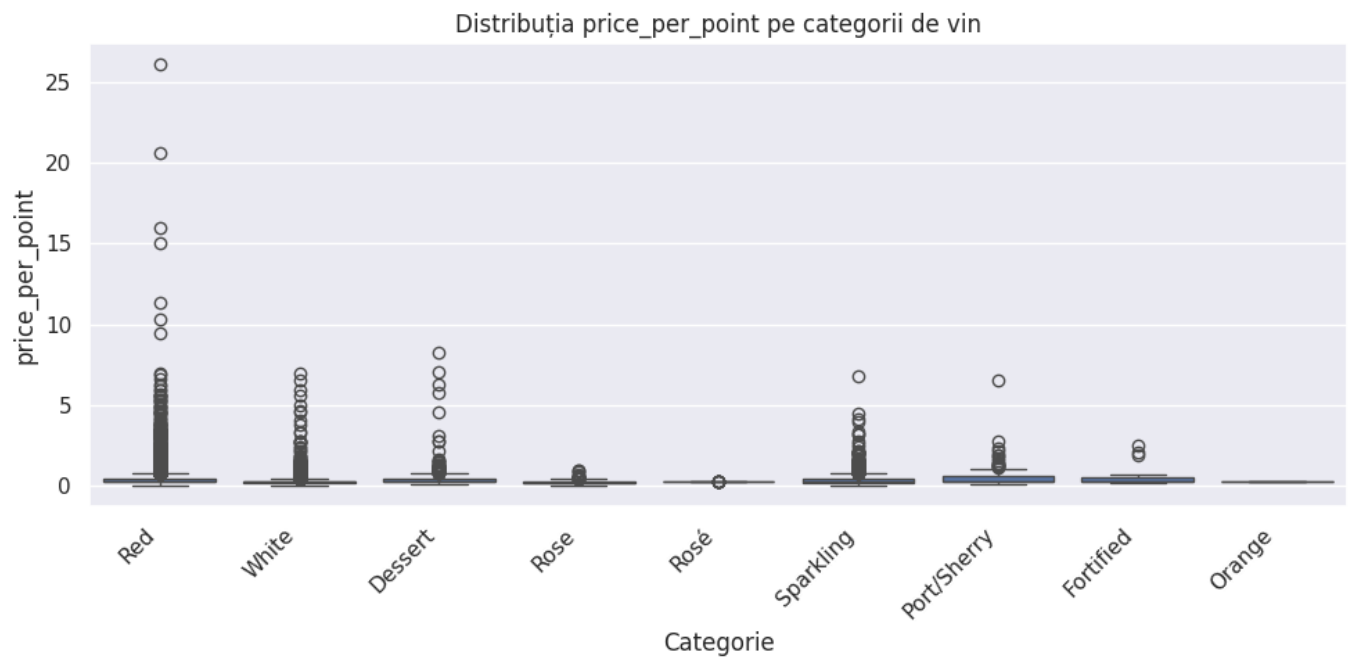
Concluzii vizuale:

- Prețurile sub 50 USD domină setul de date;
- Vinurile cu scor > 95 pot varia de la 25 USD la peste 500 USD;
- Există mai multe „best-buys” (puncte mari la preț mic).



#### 4.4. BoxPlot – price\_per\_point pe categorii

Rezultate:



- Vinurile „Red” și „Sparkling” au variație mare a raportului calitate-preț;
- Vinurile „White” și „Rosé” sunt mai stabile ca preț raportat la calitate.

#### 4.5. NLP – analiza descrierilor (wordcloud + top cuvinte)

După curățarea textului și eliminarea stopwords:

Cele mai frecvente cuvinte sunt:

- wine
- aroma
- flavor
- dry
- notes
- fruit / fruity
- finish

Wordcloud evidențiază profiluri aromatice comune vinurilor din set.

